

Reconhecimento de Emoções Faciais Utilizando Deep Learning: Um Estudo Comparativo entre DNN, CNN, MobileNetV2 e ResNet50

Ruth Maria de Lima

Curso Superior de Tecnologia em Análise e Desenvolvimento de Sistemas
Instituto Federal de Educação, Ciência e Tecnologia de Pernambuco (IFPE - Campus Jaboatão dos Guararapes)

rmdl1@discente.ifpe.edu.br

Resumo.

O reconhecimento automático de emoções faciais é uma das áreas mais relevantes da Visão Computacional e da Inteligência Artificial, permitindo que sistemas computacionais interpretem estados emocionais humanos a partir de imagens. Este trabalho apresenta a implementação e avaliação de diferentes arquiteturas de Deep Learning aplicadas ao reconhecimento de emoções faciais utilizando o dataset FER2013. Foram desenvolvidos e comparados quatro modelos: uma Rede Neural Profunda (DNN), uma Rede Neural Convolucional (CNN), MobileNetV2 e ResNet50. O processo incluiu leitura do dataset, pré-processamento, normalização dos pixels, treinamento dos modelos e avaliação por meio das métricas de acurácia, precisão, recall, F1-score, matriz de confusão e curva ROC. Os resultados demonstraram que o MobileNetV2 apresentou o melhor desempenho, alcançando acurácia de 55,64%, superando os demais modelos avaliados.

Palavras-chave: Deep Learning; Reconhecimento de Emoções Faciais; Redes Neurais Convolucionais; Transfer Learning; FER2013.

Abstract.

Automatic emotion recognition is one of the most relevant areas of Computer Vision and Artificial Intelligence, allowing computational systems to interpret human emotional states from images. This work presents the implementation and evaluation of different Deep Learning architectures applied to mechanical emotion recognition using the FER2013 dataset. Four models were developed and compared: a Deep Neural Network (DNN), a Convolutional Neural Network (CNN), MobileNetV2, and ResNet50. The process included reading the dataset, preprocessing, pixel normalization, model training, and evaluation using accuracy, precision, recall, F1-score, confusion matrix, and ROC curve metrics. The results show that MobileNetV2 performed best, achieving an accuracy of 55.64%, surpassing the other models evaluated.

Keywords: Deep Learning; Facial Emotion Recognition; Convolutional Neural Networks; Transfer Learning; FER2013.

1. Introdução

Nos últimos anos, a Inteligência Artificial (IA) tem se destacado como uma das áreas mais relevantes da Computação, impulsionando avanços significativos em diferentes setores da sociedade. Entre as diversas aplicações da IA, o reconhecimento de padrões em imagens tornou-se um tema de grande interesse devido ao seu potencial para automatizar tarefas que anteriormente dependiam exclusivamente da interpretação humana.

Dentro desse contexto, o reconhecimento de emoções faciais representa uma importante área de pesquisa da Visão Computacional. A capacidade de identificar emoções por meio das expressões faciais permite o desenvolvimento de sistemas capazes de compreender melhor o comportamento humano, possibilitando aplicações em educação, saúde, segurança, entretenimento e interação homem-computador.

As expressões faciais são consideradas uma das principais formas de comunicação não verbal. Emoções como felicidade, tristeza, medo, surpresa, raiva, nojo e neutralidade podem fornecer informações valiosas sobre o estado emocional de uma pessoa. Entretanto, a identificação automática dessas emoções apresenta desafios relacionados à variabilidade das expressões, condições de iluminação, posicionamento facial e qualidade das imagens.

O avanço das técnicas de Deep Learning possibilitou melhorias significativas nesse cenário. Modelos como Redes Neurais Profundas (DNN), Redes Neurais Convolucionais (CNN) e arquiteturas baseadas em Transfer Learning passaram a apresentar resultados superiores aos métodos tradicionais de processamento de imagens. Essas arquiteturas são capazes de aprender automaticamente características relevantes das imagens, reduzindo a necessidade de extração manual de atributos.

Diante desse cenário, este trabalho propõe a implementação e comparação de diferentes arquiteturas de Deep Learning aplicadas ao reconhecimento de emoções faciais utilizando o dataset FER2013. Foram avaliados quatro modelos distintos: uma Rede Neural Profunda (DNN), uma Rede Neural Convolucional (CNN), MobileNetV2 e ResNet50. O objetivo é analisar o desempenho dessas arquiteturas utilizando métricas clássicas de classificação e identificar qual delas apresenta melhor capacidade de generalização para o problema estudado.

2. Fundamentação Teórica

2.1 Inteligência Artificial e Deep Learning

A Inteligência Artificial consiste em uma área da Computação dedicada ao desenvolvimento de sistemas capazes de executar tarefas que normalmente exigiriam inteligência humana. Entre essas tarefas destacam-se reconhecimento de padrões, tomada de decisão, processamento de linguagem natural e visão computacional.

Dentro da Inteligência Artificial, o Machine Learning permite que os sistemas aprendam padrões a partir dos dados sem a necessidade de programação explícita. Uma das áreas mais avançadas do Machine Learning é o Deep Learning, que utiliza redes neurais artificiais compostas por múltiplas camadas para modelar problemas complexos.

Segundo Goodfellow, Bengio e Courville (2016), o Deep Learning possibilita a aprendizagem hierárquica de características, permitindo que o modelo aprenda desde atributos simples até representações mais abstratas dos dados.

2.2 Redes Neurais Profundas (DNN)

As Redes Neurais Profundas são compostas por múltiplas camadas densamente conectadas. Cada neurônio recebe entradas provenientes da camada anterior, realiza uma transformação matemática e produz uma saída para a próxima camada.

Embora as DNNs apresentem bons resultados em diversos problemas de classificação, sua aplicação em imagens apresenta limitações, pois os pixels são tratados como valores independentes, desconsiderando relações espaciais importantes entre regiões da imagem.

Neste trabalho, a DNN foi utilizada como modelo de referência para comparação com arquiteturas mais avançadas.

2.3 Redes Neurais Convolucionais (CNN)

As Redes Neurais Convolucionais foram desenvolvidas especificamente para processamento de imagens. Diferentemente das DNNs, as CNNs utilizam filtros convolucionais que percorrem a imagem identificando padrões locais, como bordas, texturas e formas.

As principais camadas presentes em uma CNN são:

- Camada Convolucional;
- Camada de Ativação;
- Camada de Pooling;
- Camada Totalmente Conectada.

Essas camadas permitem reduzir a dimensionalidade dos dados e aumentar a capacidade de extração de características relevantes.

Devido à sua eficiência em tarefas de classificação de imagens, as CNNs tornaram-se a principal arquitetura utilizada em problemas de reconhecimento facial.

2.4 Transfer Learning

O Transfer Learning consiste na reutilização de conhecimentos adquiridos por modelos previamente treinados em grandes bases de dados. Em vez de treinar uma rede neural do zero, utiliza-se uma arquitetura já treinada para servir como extratora de características.

Essa abordagem reduz significativamente o tempo de treinamento e geralmente proporciona melhores resultados quando a quantidade de dados disponíveis é limitada. Neste trabalho foram utilizados os modelos MobileNetV2 e ResNet50, ambos pré-treinados no ImageNet.

2.5 MobileNetV2

O MobileNetV2 é uma arquitetura otimizada para dispositivos com recursos computacionais limitados. Sua principal característica é a utilização de convoluções separáveis em profundidade, reduzindo significativamente a quantidade de parâmetros e operações necessárias.

Além da eficiência computacional, o MobileNetV2 apresenta excelente capacidade de generalização, sendo amplamente utilizado em aplicações móveis e embarcadas.

2.6 ResNet50

A ResNet50 é uma arquitetura profunda composta por 50 camadas. Sua principal contribuição é a utilização de conexões residuais (skip connections), que permitem o treinamento de redes mais profundas sem sofrer significativamente com o problema do desaparecimento do gradiente.

Devido à sua robustez, a ResNet50 tornou-se uma das arquiteturas mais utilizadas em tarefas de classificação de imagens e reconhecimento facial.

2.7 Reconhecimento de Emoções Faciais

O reconhecimento de emoções faciais consiste na identificação automática do estado emocional de uma pessoa por meio da análise de imagens ou vídeos. As emoções básicas normalmente consideradas são felicidade, tristeza, raiva, medo, surpresa, nojo e neutralidade.

O desenvolvimento de sistemas capazes de reconhecer emoções possui aplicações relevantes em áreas como educação adaptativa, monitoramento de pacientes, sistemas de segurança e análise de comportamento humano.

3. Trabalhos Relacionados

Diversos estudos têm investigado o uso de técnicas de Deep Learning para reconhecimento de emoções faciais.

Akhand et al. (2021) propuseram um sistema de reconhecimento de emoções faciais utilizando Transfer Learning com CNNs profundas. Os autores empregaram modelos pré-treinados e demonstraram que o uso de redes profundas permite aumentar significativamente a capacidade de generalização dos classificadores, alcançando resultados superiores aos obtidos por CNNs tradicionais.

Costa et al. (2024) desenvolveram um estudo utilizando Redes Neurais Convolucionais para classificação de emoções faciais. Os autores destacaram a importância do pré-processamento das imagens e da utilização de múltiplas camadas convolucionais para melhorar a capacidade de extração de características.

Lima (2023) investigou a detecção automática de emoções no contexto educacional, utilizando algoritmos de Deep Learning para analisar expressões faciais de estudantes durante atividades de aprendizagem. Os resultados demonstraram o potencial dessas técnicas para identificar estados emocionais que influenciam o processo de ensino-aprendizagem.

Embora os trabalhos anteriores tenham utilizado CNNs e modelos de Transfer Learning, poucos estudos realizam uma comparação direta entre arquiteturas tradicionais e modelos modernos utilizando as mesmas condições experimentais, o que justifica a realização deste trabalho.

4. Metodologia

4.1 Dataset

Foi utilizado o dataset FER2013 (Facial Expression Recognition 2013), obtido através da plataforma Kaggle, amplamente empregado em pesquisas de reconhecimento de emoções faciais. O conjunto contém 35.887 imagens em escala de cinza com resolução de 48x48 pixels distribuídas em sete categorias emocionais:

- Raiva (Angry)
- Nojo (Disgust)
- Medo (Fear)
- Felicidade (Happy)
- Neutro (Neutral)
- Tristeza (Sad)
- Surpresa (Surprise)

O conjunto de treinamento foi composto por 22.968 imagens, enquanto 5.741 imagens foram utilizadas para validação e 7.178 para teste.

4.2 Ambiente de Desenvolvimento

O desenvolvimento dos experimentos foi realizado utilizando a linguagem Python em ambiente Google Colab. Foram utilizadas bibliotecas amplamente empregadas em aplicações de Inteligência Artificial e Visão Computacional, incluindo TensorFlow, Keras, NumPy, Matplotlib e Scikit-Learn.

O TensorFlow foi utilizado para construção, treinamento e avaliação dos modelos de Deep Learning, enquanto o Scikit-Learn foi empregado no cálculo das métricas de desempenho.

4.3 Pré-processamento

As imagens passaram pelas seguintes etapas:

- Redimensionamento;
- Conversão para escala de cinza;
- Normalização dos pixels entre 0 e 1;
- Data Augmentation;
- Separação dos conjuntos de treinamento, validação e teste.

Inicialmente foi realizada a leitura automática das imagens armazenadas em diretórios específicos para treinamento e teste. Em seguida, foi aplicada a normalização dos pixels, convertendo os valores originalmente compreendidos entre 0 e 255 para o intervalo entre 0 e 1. Essa etapa é importante para melhorar a estabilidade do treinamento e acelerar a convergência dos modelos.

Data Augmentation

Para aumentar a diversidade do conjunto de treinamento e reduzir problemas de overfitting, foram aplicadas técnicas de Data Augmentation utilizando a classe ImageDataGenerator do TensorFlow.

As técnicas de Data Augmentation incluíram rotação, deslocamento horizontal, deslocamento vertical, zoom e espelhamento horizontal.

As transformações utilizadas foram:

- Rotação de até 20 graus;
- Deslocamento horizontal de 10%;
- Deslocamento vertical de 10%;
- Ampliação (zoom) de até 20%;
- Espelhamento horizontal.

Essas técnicas permitem gerar novas variações das imagens originais, aumentando a capacidade de generalização dos modelos.

4.4 Arquiteturas Implementadas

Foram avaliadas quatro arquiteturas distintas de Deep Learning.

Rede Neural Profunda (DNN)

A DNN foi utilizada como modelo base para comparação. A arquitetura foi composta por uma camada Flatten responsável por transformar a imagem em um vetor unidimensional, seguida por três camadas densas contendo 512, 256 e 128 neurônios, respectivamente. A camada de saída utilizou a função Softmax para classificação das sete emoções.

Rede Neural Convolucional (CNN)

A CNN foi composta por duas camadas convolucionais Conv2D (32 filtros) e Conv2D (64 filtros), seguidas por camadas de MaxPooling, Dropout e camadas densas (128 neurônios). Essa arquitetura permite capturar padrões espaciais presentes nas imagens faciais, tornando-a mais adequada para tarefas de reconhecimento visual.

A CNN foi composta por:

- Conv2D (32 filtros)
- Conv2D (64 filtros)
- MaxPooling
- Dropout
- Dense (128 neurônios)
- Softmax

MobileNetV2

O MobileNetV2 foi utilizado através da estratégia de Transfer Learning com Fine Tuning parcial das últimas camadas da rede, permitindo adaptar os pesos pré-treinados ao dataset FER2013.

ResNet50

Foi utilizada a arquitetura ResNet50 pré-treinada no ImageNet, mantendo congeladas as camadas convolucionais e treinando apenas as camadas finais de classificação.

4.5 Métricas de Avaliação

A avaliação dos modelos foi realizada por meio das seguintes métricas:

- Acurácia;
- Precisão;
- Recall;
- F1-score;
- Matriz de Confusão;
- Curva ROC Multiclasse.

A utilização conjunta dessas métricas permite uma análise mais completa do desempenho dos classificadores, especialmente em problemas multiclasse como o reconhecimento de emoções faciais.

5. Resultados e Discussão

A Tabela 1 apresenta os resultados obtidos pelos quatro modelos avaliados.

Tabela 1 – Comparação de desempenho dos modelos.

	Modelo	Acurácia	Precisão	Recall	F1-score
0	DNN	0.3273	0.2938	0.2381	0.1979
1	CNN	0.4696	0.3711	0.3855	0.3624
2	MobileNetV2	0.5564	0.6331	0.4812	0.4858
3	ResNet50	0.4167	0.3348	0.3338	0.3178

Fonte: O autor, 2026.

Os resultados demonstram uma evolução significativa do desempenho à medida que arquiteturas mais especializadas para processamento de imagens foram utilizadas.

A DNN apresentou o pior desempenho entre os modelos avaliados, alcançando acurácia de apenas 32,73%. Esse comportamento era esperado, pois redes totalmente conectadas não exploram adequadamente a estrutura espacial das imagens, tratando cada pixel de forma independente.

A CNN apresentou uma melhora expressiva, atingindo a acurácia de 46,96%. Esse ganho evidencia a capacidade das camadas convolucionais em extrair características relevantes das expressões faciais, como contornos, texturas e padrões presentes nos rostos.

O melhor resultado foi obtido pelo MobileNetV2, que alcançou acurácia de 55,64%, precisão de 63,31% e F1-score de 48,58%. Esse desempenho superior pode ser atribuído à utilização de Transfer Learning e Fine Tuning parcial, permitindo aproveitar conhecimentos previamente aprendidos em grandes bases de imagens e adaptá-los ao problema específico de reconhecimento de emoções faciais.

Apesar de ser uma arquitetura mais profunda, o ResNet50 apresentou desempenho inferior ao MobileNetV2, alcançando acurácia de 41,67%. Uma possível justificativa é que o modelo foi utilizado com as camadas convolucionais congeladas, limitando sua capacidade de adaptação às características específicas do dataset FER2013.

A análise das matrizes de confusão mostrou que a emoção 'happy' apresentou os melhores índices de classificação **no conjunto de testes do FER2013**, embora o modelo ainda apresente erros de generalização quando aplicado a imagens externas ao conjunto de treinamento."

As curvas ROC indicaram que o MobileNetV2 apresentou maior capacidade discriminativa entre as classes emocionais, reforçando seu melhor desempenho geral.

Durante os testes do MVP desenvolvido em Streamlit, observou-se que algumas imagens externas ao conjunto FER2013 foram classificadas incorretamente. Em determinados casos, imagens com expressão facial claramente associada à felicidade foram classificadas como tristeza, acompanhadas de baixos níveis de confiança (inferiores a 60%). Esse comportamento está relacionado à capacidade limitada de generalização do modelo, cuja acurácia foi de aproximadamente 55,64% no conjunto de testes. Além disso, o dataset FER2013 apresenta desafios conhecidos, como baixa resolução das imagens (48×48 pixels), desbalanceamento entre algumas classes emocionais e grande variabilidade de iluminação, pose e intensidade das expressões faciais, fatores que influenciam diretamente o desempenho dos classificadores. Dessa forma, o resultado obtido pelo MVP é coerente com as limitações observadas durante a etapa experimental e evidencia a necessidade de aprimoramentos para aplicações em cenários reais.

Embora o MobileNetV2 tenha apresentado o melhor desempenho entre os modelos avaliados, o sistema ainda apresentou dificuldades na classificação de algumas emoções em imagens reais, principalmente quando as expressões eram semelhantes ou quando a confiança da predição era baixa. Como trabalhos futuros, pretende-se utilizar conjuntos de dados mais robustos, aplicar técnicas adicionais de aumento de dados (Data Augmentation), realizar Fine Tuning mais profundo das arquiteturas pré-treinadas e empregar detectores faciais para isolar a região do rosto antes da classificação, visando aumentar a capacidade de generalização do modelo.

6. Comparação com os Trabalhos Relacionados

Os resultados obtidos neste trabalho corroboram os achados de Akhand et al. (2021), que demonstraram a eficácia do Transfer Learning em tarefas de reconhecimento emocional. Assim como observado pelos autores, a utilização de modelos pré-treinados resultou em desempenho superior quando comparada às arquiteturas tradicionais.

Os resultados também são consistentes com Costa et al. (2024), que identificaram vantagens significativas das Redes Neurais Convolucionais sobre modelos totalmente

conectados. Em ambos os estudos, as CNNs apresentaram melhor capacidade de extração de características faciais.

Da mesma forma, os achados reforçam as conclusões de Lima (2023), que evidenciou o potencial do Deep Learning para identificação automática de emoções em contextos educacionais.

Entretanto, diferentemente dos trabalhos analisados, este estudo realizou uma comparação simultânea entre quatro arquiteturas distintas utilizando o mesmo dataset, o mesmo processo de treinamento e o mesmo conjunto de métricas, permitindo uma avaliação mais abrangente do desempenho dos modelos.

Tabela 2 – Comparação dos trabalhos relacionados

Autor / Ano	Dataset	Modelos utilizados	Métricas avaliadas	Principais resultados
Akhand et al. (2021)	FER2013	CNN + Transfer Learning (VGG16, ResNet50, InceptionV3, MobileNetV2 e outros modelos pré-treinados)	Acurácia	Demonstraram que o uso de Transfer Learning melhora significativamente o reconhecimento de emoções faciais em comparação com CNNs treinadas do zero. O melhor modelo alcançou aprox. 73% de acurácia no FER2013.
Costa et al. (2024)	FER2013	CNN	Acurácia e matriz de confusão	Os autores verificaram que redes convolucionais conseguem extrair melhor as características das expressões faciais, obtendo desempenho superior às redes totalmente conectadas e destacando a importância do pré-processamento das imagens.
Lima (2023)	FER2013	CNN e técnicas de Deep Learning	Acurácia e matriz de confusão	O trabalho demonstrou que modelos de Deep Learning podem identificar automaticamente emoções faciais em ambientes educacionais, contribuindo para o acompanhamento do processo de aprendizagem dos estudantes.
Este trabalho (2026)	FER2013	DNN, CNN, MobileNetV2 e ResNet50	Acurácia, Precisão, Recall, F1-score, Matriz de Confusão e Curva ROC	O MobileNetV2 apresentou o melhor desempenho entre os modelos avaliados, alcançando 55,64% de acurácia, seguido pela CNN (46,96%), ResNet50 (41,67%) e DNN (32,73%).

Fonte: O autor, 2026.

A Tabela 2 apresenta uma comparação dos principais trabalhos utilizados como base para esta pesquisa. Observa-se que todos empregam o dataset FER2013 e utilizam arquiteturas de Deep Learning para o reconhecimento de emoções faciais. Entretanto, a maioria dos estudos concentra-se em um número reduzido de modelos ou em uma única arquitetura baseada em CNN e Transfer Learning.

7. Referências

AKHAND, M. A. H.; ROY, S.; SIDDIQUE, N.; KAMAL, M. A. S.; SHIMAMURA, T. Facial Emotion Recognition Using Transfer Learning in the Deep CNN. *Electronics*, Basel, v. 10, n. 9, p. 1036, 2021. Disponível em: <https://www.mdpi.com/2079-9292/10/9/1036>. Acesso em: 20 maio 2026.

COSTA, Nicolas Emanuel Alves Costa; SOARES, Anabel Marinho Soares; SOUSA, Thiago Luan Moreira Sousa; REGO, Rosana C. B. Reconhecimento de expressões faciais utilizando redes neurais convolucionais. In: CONGRESSO BRASILEIRO INTERDISCIPLINAR EM CIÊNCIA E TECNOLOGIA, 5., 2024. Anais [...]. Online: Even3, 2024. Disponível em: <https://static.even3.com/anais/820462.pdf>. Acesso em: 20 maio 2026.

KAGGLE. *FER2013 Dataset*. Disponível em: <https://www.kaggle.com/datasets/msambare/fer2013>. Acesso em: 20 maio 2026.

LIMA, Paulo Victor Borges Oliveira. *Deteccção automática de emoções no aprendizado de algoritmos*. 2023. 33 f. Monografia (Bacharelado em Ciência da Computação) – Universidade Federal do Maranhão, São Luís, 2023. Disponível em: <https://monografias.ufma.br/jspui/bitstream/123456789/6934/1/Paulo%20Victor%20Borges%20Oliveira%20Lima.pdf>. Acesso em: 20 maio 2026.

TENSORFLOW. *TensorFlow Documentation*. Disponível em: <https://www.tensorflow.org>. Acesso em: 20 maio 2026.